

Web Kazıma Tabanlı Kentsel Haber İzleme ve Harita Üzerinde Görselleştirme Sistemi

Burak Kılıcı
Bilgisayar Mühendisliği Bölümü
Kocaeli Üniversitesi
Öğrenci No: 230202111
230202111@kocaeli.edu.tr

Özet—Bu çalışmada, Kocaeli ilindeki beş yerel haber sitesinden trafik kazası, yangın, elektrik kesintisi, hırsızlık ve kültürel etkinlik haberlerini otomatik olarak toplayan, işleyen ve harita üzerinde gösteren bir sistem geliştirilmiştir. Sistem Python ile yazılmış, veriler MongoDB’de saklanmıştır. Haber metinleri temizlenip normalize edildikten sonra ağırlıklı anahtar kelime yöntemiyle sınıflandırılmış, olay yeri kural tabanlı bir yöntemle metinden çıkarılarak koordinata dönüştürülmüştür. Farklı sitelerde yayımlanan aynı haberler, çok dilli bir cümle gömme (embedding) modeliyle ölçülen %90 ve üzeri kosinüs benzerliği ile tespit edilip tek kayıta birleştirilmiştir. Gerçek verilerle yapılan ilk taramada 39 haber kaydedilmiş, 9 haber başka sitelerdeki kopyalarıyla birleştirilmiştir. Sınıflandırma hatalarının analiziyle geliştirilen kurallar sonucunda yanlış sınıflandırılan 15 haberin tamamı elenmiştir. Kalan haberlerin %66,7’sinde olay yeri ilçe merkezinden daha spesifik (mahalle, cadde veya belirli bir yer düzeyinde) bulunmuştur.

Anahtar Kelimeler—web kazıma, haber sınıflandırma, konum çıkarımı, geocoding, cümle gömme, MongoDB, harita görselleştirme

I. GİRİŞ

Şehir yaşamını etkileyen trafik kazaları, yangınlar, elektrik kesintileri ve kültürel etkinlikler gibi olaylar çok sayıda yerel haber sitesinde dağınık biçimde yayımlanmaktadır. Bir kullanıcının çevresindeki olayları takip etmesi için bu siteleri tek tek gezmesi gerekmekte, aynı olay farklı sitelerde farklı başlıklarla tekrar karşısına çıkmaktadır. Ayrıca haber metinleri olayın yerini çoğunlukla “Körfez ilçesi Yeniyalı Mahallesi Cahit Zarifoğlu Caddesi” gibi serbest metin olarak verdiği için, olayların mekânsal dağılımını görmek mümkün olmamaktadır.

Bu projede bu soruna yönelik uçtan uca bir sistem geliştirilmiştir. Sistem; (i) belirlenen beş yerel siteden son üç günün haberlerini otomatik olarak toplar, (ii) metinleri temizler ve beş olay türünden birine atar, (iii) metindeki konum ifadelerini bularak koordinata dönüştürür, (iv) farklı kaynaklardaki aynı haberleri birleştirir ve (v) sonuçları türüne göre renklendirilmiş işaretlerle etkileşimli bir harita üzerinde sunar.

Raporun geri kalanı şöyle düzenlenmiştir: Bölüm II sistem mimarisini, Bölüm III–VIII her işlem adımını, Bölüm IX kullanıcı arayüzünü, Bölüm X gerçek verilerle elde edilen sonuçları, Bölüm XI karşılaşılan sorunları ve Bölüm XII sonuçları ele almaktadır.

Tablo I
MONGODB KOLEKSİYONLARI

Koleksiyon	İçerik
news	Haritada gösterilen haberler: tür, başlık, içerik, konum metni, enlem/boylam, yayın tarihi, kaynak listesi, sınıflandırma puanları
processed_urls	İncelenen her linkin sonucu ve elenme nedeni
geocache	Geocoding önbellegi (servis + sorgu)
scrape_runs	Her tarama çalışmasının özeti

II. SİSTEM MİMARİSİ


Sistem Python 3.11 ile geliştirilmiştir. Kullanılan başlıca bileşenler şunlardır: web kazıma için requests ve BeautifulSoup [9], veritabanı için MongoDB [4], zamanlanmış görevler için APScheduler [11], benzerlik ölçümü için sentence-transformers [1] ve web sunucusu için Flask [10]. Arayüz HTML, CSS ve JavaScript ile yazılmıştır.

İşlem hattı Şekil 1’de gösterilmiştir. Bir tarama çalışmasında beş site paralel olarak taranır. Toplanan haberler ardından tek tek temizleme, sınıflandırma, Kocaeli kontrolü, benzerlik kontrolü, konum çıkarımı ve geocoding adımlarından geçirilir. Bir haber herhangi bir adımda elenirse (ör. hiçbir türe girmiyorsa) bu sonuç nedeniyle birlikte kaydedilir ve haber sonraki adımlara geçmez. MongoDB’de kullanılan koleksiyonlar Tablo I’da verilmiştir.

III. WEB KAZIMA MODÜLÜ

A. Kaynak Sitelerin Yapısı

Proje dokümanında verilen beş sitenin yapısı incelendiğinde, Çağdaş Kocaeli, Özgür Kocaeli, Ses Kocaeli ve Bizim Yaka’nın aynı içerik yönetim sistemini kullandığı görülmüştür. Bu sitelerde haber adresleri /haber/{id}/{başlık} kalıbındadır. Bu yüzden dört site için tek bir ortak sınıf yazılmış, siteye özel yalnızca ad ve adres bilgisi alt sınıflarda tanımlanmıştır. Yeni Kocaeli farklı bir yapıya (/haber/{kategori}/{başlık}/{id}.html) sahip olduğu için ayrı bir sınıfla ele alınmıştır.



Şekil 1. Sistemin işlem hattı. Her haber soldan sağa adımlardan geçer; elenen haberler nedeniyle birlikte `processed_urls` koleksiyonuna yazılır.

B. Link Keşfi

Haber linkleri üç kaynaktan toplanır: RSS beslemeleri, site haritaları ve liste sayfaları (ana sayfa, kategori sayfaları ve “kaza”, “yangın” gibi etiket sayfaları). Bulunan her link, sitenin haber adresi kalıbına karşılık gelen bir düzenli ifadeyle kontrol edilir; menü, yazar ve reklam linkleri bu şekilde elenir. Linkler sorgu parametrelerinden arındırılarak tek biçime getirilir.

C. Son Üç Gün Kuralı

RSS beslemesinden yayın tarihi gelen eski haberler hiç indirilmez. Tarihi bilinmeyen linkler için şu gözlemden yararlanılmıştır: Bu sitelerde haber numaraları zamanla artmaktadır. Linkler numaraya göre yeniden eskiye sıralanır; arka arkaya 12 eski habere rastlandığında o sitenin taraması durdurulur. Gün sayısı ayarlanabilir; otomatik tarama son üç günü kapsar.

D. Haber Sayfasının Ayrıştırılması

Haber siteleri, arama motorları için sayfalarına `schema.org NewsArticle` [12] biçiminde yapılandırılmış veri (JSON-LD) eklemektedir. Başlık, yayın tarihi ve haber metni öncelikle bu veriden okunur. Bulunamazsa sırasıyla Open Graph meta etiketleri, `<time>` etiketi ve sayfadaki “22 Eylül 2026 16:18” gibi Türkçe tarih ifadeleri denir. Haber gövdesi için önce siteye özel CSS seçicileri, bulunamazsa doğrudan altında en çok paragraf metni bulunan HTML bloğu kullanılır. Tüm tarihler UTC olarak saklanır; saat dilimi belirtilmemişse Türkiye saati varsayılır.

E. Otomatik ve Tekrar Tetiklenebilir Çalışma

Tarama, uygulama açıldıktan birkaç saniye sonra ve sonrasında düzenli aralıklarla (varsayılan 60 dakika) APScheduler ile otomatik olarak başlatılır. Ayrıca arayüzdeki “Haberleri tara” düğmesi istenen gün sayısı için taramayı elle başlatır. Bir kilit mekanizması, iki taramanın aynı anda çalışmasını engeller.

İstekler arasında bekleme süresi bırakılır ve ağ hatalarında istek üç kez tekrarlanır. Sitelerin bot koruması devreye girerse (HTTP 403/429/503), istek gerçek bir tarayıcının TLS parmak izini taklit eden `curl_cffi` kütüphanesiyle yeniden denir.

IV. VERİ TEMİZLEME VE ÖN İŞLEME

Proje dokümanında istenen her ön işleme adımı ayrı bir fonksiyon olarak gerçekleştirilmiştir:

- 1) *HTML etiket temizliği*: Betik, stil, `iframe`, menü, görsel ve benzeri etiketler tamamen silinir; paragraflar metin satırlarına dönüştürülür.
- 2) *Reklam ve alakasız bölümler*: `class` veya `id` değerinde “reklam”, “ilgili”, “paylaş”, “yorum” gibi ifadeler geçen bloklar silinir. Ana haber kapsayıcısının yanlışlıkla silinmemesi için, sayfadaki paragraf metninin %60’ından fazlasını içeren bloklar korunur. Ayrıca “ABONE OL”, ajans adları ve görsel altında tekrarlanan başlık gibi kalıp satırlar çıkarılır.
- 3) *Metin normalizasyonu*: Unicode birleştirme (NFC) uygulanır; farklı tırnak, kesme ve tire karakterleri tek biçime indirilir.
- 4) *Özel karakter temizliği*: Harf, rakam ve temel noktalama dışındaki karakterler (emoji vb.) silinir; tekrarlanan noktalama sadeleştirilir.
- 5) *Fazla boşluk temizliği*: Ardışık boşluklar tek boşluğa indirilir.

Analiz için metnin ayrıca küçük harfli ve noktalamasız bir sürümü üretilir. Burada Türkçeye özgü bir sorun çözülmüştür: Python’un `lower()` fonksiyonu “İ” harfini tek bir “i” yerine “ı” ve birleşik nokta karakterinden oluşan iki karaktere, “I” harfini de “i” yerine “ı” harfine dönüştürür. Bu yüzden büyük/küçük harf dönüşümü Türkçe kurallarına göre ayrıca yazılmıştır.

V. HABER TÜRÜ SINIFLANDIRMA

A. Yöntem

Sınıflandırma, ağırlıklı anahtar kelime puanlamasına dayanır. Her tür için anahtar kelimeler ve ağırlıkları Tablo II’de verilmiştir. Ağırlıklar dört düzeydedir: türü neredeyse kesin gösteren ifadeler (+4/+5, ör. “trafik kaza”), güçlü ipuçları (+3, ör. “çarptı”), zayıf ipuçları (+1/+2, ör. “sürücü”) ve yanlış eşleşmeleri bastıran negatif kelimeler (ör. “iş kazası” için -6, “su kesintisi” için -5).

Kelimeler varsayılan olarak kök biçiminde eşleşir; böylece “yangın” kelimesi “yangında” ve “yangını” biçimlerini de bulur. Kök eşleşmenin yanlış sonuç verdiği kelimeler (ör. “kaza” kökü “kazanç” kelimesini de bulur) yalnızca tam kelime olarak eşleşecek şekilde işaretlenmiştir. Başlıktaki eşleşmeler iki kat sayılır ve aynı kelime en fazla üç kez puanlanır. Yöntem Algoritma 1’de özetlenmiştir.

Algoritma 1 Haber türü sınıflandırma

Girdi: başlık b , içerik m , kelime tablosu K

Çıktı: tür veya YOK

```
1:  $b', m' \leftarrow \text{normalize}(b), \text{normalize}(m)$ 
2:  $p[t] \leftarrow 0$  (her tür için);  $G \leftarrow \emptyset$ 
3: her tür  $t$  ve  $(k, w) \in K[t]$  için
4:    $p[t] += w \cdot (2 \cdot \text{say}(k, b') + \text{say}(k, m'))$ 
5:   eğer  $k$  eşleşti ve  $w \geq 3$  ise
6:      $G \leftarrow G \cup \{t\}$ 
7:  $A \leftarrow \{t \mid t \in G, p[t] \geq 4\}$ 
8: eğer  $A = \emptyset$  ise döndür YOK
9:  $p^* \leftarrow \max_{t \in A} p[t]$ ;  $C \leftarrow \{t \in A \mid p[t] \geq 0,6 p^*\}$ 
10: döndür  $C$  içinde öncelik sırası en yüksek tür
```

B. Güçlü Kelime Şartı

Gerçek verilerle yapılan ilk denemede, “şüpheli”, “yakalandı” ve “tutuklandı” gibi zayıf kelimelerin toplamının eşiği aştığı ve bir cinayet haberinin “Hırsızlık” olarak sınıflandırıldığı görülmüştür. Bu yüzden bir türün seçilebilmesi için, o türün ağırlığı en az 3 olan bir kelimesinin haberde geçmesi şartı eklenmiştir (G kümesi). Zayıf kelimeler artık yalnızca destekleyici rol oynamaktadır.

C. Öncelik Sırası

Bir haber birden fazla türe uyuyorsa (puanı en yüksek puanın %60'ına ulaşan türler), şu öncelik sırası uygulanır: Yangın > Trafik Kazası > Hırsızlık > Elektrik Kesintisi > Kültürel Etkinlikler. Sıralamada can ve mal güvenliğini en doğrudan tehdit eden ve acil müdahale gerektiren olay önce gelir. Örneğin “zincirleme kazada araç alev aldı” haberinde trafik puanı daha yüksek olsa da iki tür birlikte aday olduğunda haber “Yangın” olarak etiketlenir. Sınıflandırma sonucu, tür puanları ve eşleşen kelimelerle birlikte veritabanında saklanır.

VI. KONUM BİLGİSİ ÇIKARIMI

Konum çıkarımı kural tabanlı bir yöntemle yapılır ve üç adımdan oluşur.

A. Tüm Konum İfadelerinin Bulunması

Metindeki konum ifadeleri beş seviyede aranır (Tablo III). Mahalle, cadde ve sokak için “Mahallesi”, “Caddesi”, “Sokak” gibi anahtar kelimeler ve kısaltmaları (“Mah.”, “Cad.”, “Sk.”) düzenli ifadelerle bulunur. Yer adının kendisi, anahtar kelimenin hemen solundaki büyük harfle başlayan kelimeler geriye doğru toplanarak çıkarılır (en fazla 4–5 kelime). Bu sırada:

- Cümle başında büyük harfle yazılan “Olay”, “Kaza”, “Böylelikle” gibi kelimeler addan atılır.
- Kesme işaretli kelimeler adın dışında bırakılır (“İzmit’in Yenişehir Mahallesi” → “Yenişehir Mahallesi”).
- Başka bir ile ait adresler eklenmez (“İznik’in Sarıalan mahallesi”).

Belirli yerler için kavşak, sapak, köprü, park, stadyum, kongre merkezi, iskele gibi 45 yer türü tanımlanmıştır. “Hastanesi” bu listeye bilinçli olarak alınmamıştır, çünkü haberlerde hastane olay yerini değil, yaralının götürüldüğü yeri belirtir (“Kocaeli Şehir Hastanesi’ne kaldırıldı”). Anahtar kelime içermeyen “Sekapark”, “Ormanya” gibi bilinen yerler

için ayrıca küçük bir yer sözlüğü kullanılır. İlçe tespitinde “Gölcük Mahallesi” gibi mahalle adlarının ve “İzmit Körfezi” gibi ifadelerin ilçe sayılmaması için ilçe adından sonra gelen kelime de kontrol edilir.

B. Kocaeli Kontrolü

Yerel siteler başka illerin haberlerini de yayımlamaktadır (ör. “Bursa’nın Kestel ilçesinde orman yangını”). Bu yüzden metindeki Kocaeli ve ilçe anımları ile diğer il ve komşu ilçe (Tuzla, Sapanca, Çiftlikköy vb.) anımları puanlanır. Başlık ve ilk cümle iki kat ağırlıklıdır. “İstanbul istikametinde” veya “Yalova-İzmit kara yolu” gibi yön ve güzergâh ifadeleri sayılmaz. Dış yer puanı Kocaeli puanından yüksekse haber kapsam dışı kabul edilir. “Aydın” ve “Kartal” gibi aynı zamanda soyadı olabilen yer adları, ancak ek veya “ili/ilçesi” ifadesiyle birlikte geçerse sayılır.

C. En Spesifik Konumdan Genele Sorgular

Bulunan ifadelerden, en spesifikten en genele sıralı geocoding sorguları üretilir. Örneğin “Kocaeli’nin İzmit ilçesi Yenişehir Mahallesi Paşa Caddesi Dönmez Sokak’ta” ifadesi için şu sorgular üretilir:

- 1) Dönmez Sokak, Paşa Caddesi, Yenişehir Mahallesi, İzmit, Kocaeli
- 2) Paşa Caddesi, Yenişehir Mahallesi, İzmit, Kocaeli
- 3) Yenişehir Mahallesi, İzmit, Kocaeli
- 4) İzmit, Kocaeli

Sorgular sırayla denenir ve doğrulamadan geçen ilk sonuç kullanılır (Bölüm VII). Böylece adres net değilse dokümanda istendiği gibi mümkün olan en spesifik konum alınır. Hiç konum ifadesi bulunamayan haberler haritada gösterilmez. Bulunan tüm aday ifadeler, seçilen sorgu ve denenen sorguların sonuçları veritabanında saklanır; bu bilgiler hem arayüzdeki bilgi penceresinden hem de bir komut satırı aracılığıyla görüntülenebilir.

VII. GEOCODING

A. Servisler

Sistem iki geocoding servisini destekler: Google Geocoding API [5] ve OpenStreetMap Nominatim [7]. Her iki servis de ortak bir sınıftan türetilmiştir; önbellek, doğrulama ve sıralı deneme mantığı ortaktır, yalnızca API çağrısı ve cevabın ortak biçime dönüştürülmesi farklıdır. Kullanılacak servis yapılandırma dosyasından seçilir. Google API anahtarı koda yazılmaz; yalnızca sunucu tarafında okunan ve sürüm kontrolü dışında tutulan bir .env dosyasında saklanır ve tarayıcıya hiçbir zaman gönderilmez. Nominatim kullanım kuralları gereği saniyede en fazla bir istek yapılır ve uygulama kendini tanıtan bir *User-Agent* başlığı gönderir.

B. Önbellek

Her sorgunun sonucu, servis adıyla birlikte geocache koleksiyonuna yazılır. Aynı adres tekrar sorulduğunda önce bellekteki, sonra veritabanındaki önbelleğe bakılır ve API çağrısı yapılmaz. Bulunamayan adresler de önbelleğe yazılır; böylece bunlar için de tekrar çağrı yapılmaz. Buna karşılık

Tablo II
SINIFLANDIRMADA KULLANILAN ANAHTAR KELİMELER VE AĞIRLIKLARI

Haber türü	Ağırlık	Anahtar kelimeler
Yangın	+4 +3 +2 +1 -2 -5	yangın, küle dön, kül oldu, kundak alevlere teslim, alev aldı, alev alev, tutuştu, söndürül, dumandan etkilen, yandı [†] tutuşma, söndürme, yanarak alev, itfaiye, patlama yangın söndürme tüpü tatbikat
Trafik Kazası	+5 +4 +3 +2 +1 -3 -4 -5 -6	trafik kaza, zincirleme kaza yayaya çarp kafa kafaya, takla at, şarampol, kontrolden çık, direksiyon hakimiyet, çarpıştı, çarpışma, çarpışan, arkadan çarp, devrildi, devrilen, sürücüsü yaralandı, maddi hasar, kaza [†] , kazada [†] , kazaya [†] , kazayı [†] , kazayla [†] , kazazede zincirleme, bariyer, refüj, kazası [†] , kazalar otomobil, motosiklet, kamyon, tır [†] , tırın [†] , minibüs, sürücü, yaralandı, ambulans, trafik ekip, plakalı asfalt, ihale yol çalışma yeni kavşak, kavşak düzenleme, kavşak çalışma iş kaza, ağaç devril, direk devril
Hırsızlık	+5 +4 +3 +1 -3 -4 -5	hırsız çalıntı, gasp, soygun, soyuldu, yankesici, kapkaç çaldı [†] , çaldılar, çalındı, çalınan, çalarak, çaldığı, çaldıkları ziynet, ele geçirildi, şüpheli, gözaltına, yakalandı, tutuklandı uyuşturucu, dolandırıcılık usulsüzlük, rüşvet, kapı çal, kapısını çal, zil çal öldür, cinayet, istiklal marşı
Elektrik Kesintisi	+5 +4 +3 +2 +1 -3 -5	elektrik kesinti, elektrikler kesil, enerji kesinti, elektrik verilemeye, elektrik verilmeye elektrikler gitti, elektriksiz, planlı kesinti, plansız kesinti, elektrik arıza kesinti yapılacak, kesinti uygulanacak sedaş, karanlıkta kal trafo, elektrik, kesinti seçim, meclis üye su kesinti, doğalgaz kesinti, doğal gaz kesinti, sanayi odası
Kültürel Etkinlikler	+4 +3 +2 +1 -3 -4 -6	konser [†] , konseri, konserde, konsere, konserler, konserden, tiyatro, festival, dinleti, resital, kitap fuar sergi [†] , sergisi, sergide [†] , sergiye [†] , sergiler, söyleşi, müzikal, opera [†] , operası, operada [†] , bale [†] , orkestra, korusu, kültür sanat, imza günü, şenlik, panayır, sanatsever, kültür ve sanat, sempozyum, resim yarışması, film gösterim, sanat etkinli koro [†] , kültürel, etkinlik, sahne, gösterim, sinema, şiir, sanatçı, müze, kültür merkezi, kitap okuma gösteri, fuar, atölye, konferans transfer, lig [†] , aday, seçim, atama, atandı operasyon, tutuklan, gözaltı, futbol, maç [†] , maçı uyuşturucu

Kelimeler kök olarak eşleşir; Türkçe ekleriyle birlikte de bulunur (ör. *yangın* → *yangında*). [†] ile işaretli kelimeler yalnızca tam kelime olarak eşleşir (ör. *kaza* eşleşir, *kazanç* eşleşmez). Negatif ağırlıklar yanlış eşleşmeleri bastırır. Başlıktaki eşleşmeler 2 kat sayılır. Bir türün seçilebilmesi için haberde o türün ağırlığı en az 3 olan bir kelimesi geçmeli ve toplam puanı en az 4 olmalıdır. Puanı en yüksek puanın en az %60'ı olan türler arasından öncelik sırasına göre seçim yapılır: Yangın > Trafik Kazası > Hırsızlık > Elektrik Kesintisi > Kültürel Etkinlikler.

Tablo III
KONUM SEVİYELERİ VE GERÇEK VERİDEN ÖRNEKLER

Sv.	Tür	Örnek
5	Cadde/sokak	Kavak Caddesi, Arapçeşme Mahallesi, Gebze
4	Belirli yer	Kocaeli Kongre Merkezi; Akse Sapağı, Gebze
3	Mahalle/köy	Çınarlı Mahallesi, Derince
2	Yol	D-100 Karayolu, Körfez
1	İlçe	Kartepe

kota aşımı, ağ hatası veya geçersiz anahtar gibi geçici hatalar önbellege yazılmaz. Bu durumdaki haberler sonraki taramada otomatik olarak yeniden denir.

C. Doğrulama

Bir sonucun kabul edilmesi için şu koşulların hepsi sağlanmalıdır:

- 1) Koordinat Kocaeli'yi çevreleyen dikdörtgen içinde olmalıdır.
- 2) Adresin il bileşeni "Kocaeli" olmalıdır. Bu kontrol, dikdörtgenin içinde kalan Sapanca gibi komşu ilçeleri eler.
- 3) İlçe biliniyorsa sonuçtaki ilçe ile eşleşmelidir.
- 4) Sonuç istenen seviyeye yeterince yakın olmalıdır. Örneğin bir mahalle sorgusuna yalnızca ilçe merkezi dönerse sonuç reddedilir ve bir sonraki sorguya geçilir.

Hiçbir sorgu doğrulamadan geçemezse haber kaydedilmez. Koordinatlar hem lat/long alanlarında hem de MongoDB'nin coğrafi sorgularına uygun GeoJSON biçiminde saklanır.

Tablo IV
REST API UÇLARI

Uç	İşlev
GET /api/news	Tür, ilçe ve tarih aralığına göre filtrelenmiş haberler
GET /api/news/<id>	Tek haber; konum ve sınıflandırma ayrıntıları
GET /api/stats	Aynı filtrelerle tür başına haber sayısı
POST /api/scrape	Taramayı istenen gün sayısı ile başlatır
GET /api/scrape/status	Taramanın durumu ve son çalışmanın özeti

VIII. TEKRARLI HABER TESPİTİ

Tekrar kontrolü iki katmanda yapılır.

Link düzeyi: Aynı link ikinci kez işlenmez. Bu kural hem incelenen linklerin kaydıyla hem de `sources.url` alanı üzerindeki tekil (unique) indeksle veritabanı seviyesinde garanti altına alınmıştır.

İçerik düzeyi: Farklı sitelerde yayımlanan aynı haber, cümle gömme yöntemiyle tespit edilir. Bunun için Sentence-BERT [1] mimarisine dayanan ve bilgi damıtma (knowledge distillation) ile çok dilli hale getirilmiş paraphrase-multilingual-MiniLM-L12-v2 modeli [2], [3] kullanılmıştır. Model Türkçe dahil 50’den fazla dili destekler ve her metni 384 boyutlu bir vektöre dönüştürür. Haberin başlığı ve içeriğinin başı vektöre çevrilir. Vektörler birim uzunluğa normalize edildiği için iki vektörün iç çarpımı kosinüs benzerliğine eşittir:

$$\text{benzerlik}(a, b) = \frac{a \cdot b}{\|a\| \|b\|} \quad (1)$$

Yeni haber, yayın tarihi ± 3 gün içindeki kayıtlı haberlerle karşılaştırılır. Benzerlik dokümanda belirtilen 0,90 eşliğine ulaşırsa yeni kayıt açılmaz; yeni kaynak mevcut haberin `sources` listesine eklenir ve haritada tüm kaynaklar listelenir. Haberler yayın tarihine göre eskiden yeniye işlendiği için olayı ilk yayımlayan site ana kaynak olur.

IX. HARİTA VE KULLANICI ARAYÜZÜ

Arayüz, Flask üzerinde çalışan bir REST API’den veri alan tek sayfalık bir web uygulamasıdır (Tablo IV, Şekil 2). Harita Kocaeli il merkezinde (İzmit) açılır. Her haber için türüne göre renklendirilmiş ve sembollü bir işaret eklenir: trafik kazası için kırmızı/araç, yangın için turuncu/alev, elektrik kesintisi için koyu lacivert/şimşek, hırsızlık için mor/maske ve kültürel etkinlik için yeşil/nota. Aynı koordinattaki işaretlerin üst üste binmemesi için bunlar altın açığı ile oluşturulan küçük bir sarmal üzerinde dağıtılır.

İşarete tıklandığında açılan bilgi penceresinde başlık, tarih, konum, haberin yer aldığı tüm kaynaklar ve haberi yeni sekmede açan “Habere git” düğmesi bulunur. Açılır bir bölümde metinde tespit edilen tüm konum adayları gösterilir. Haber türü, ilçe ve tarih aralığı filtreleri sayfa yeniden yüklenmeden çalışır: filtre değiştiğinde API’den yeni veri alınır ve yalnızca işaretler güncellenir. Haber metinleri dış kaynaklardan geldiği

için sayfaya her zaman düz metin olarak yazılır; böylece haber içine gizlenmiş olası zararlı kodlar çalıştırılmaz.

Harita kodu küçük bir adaptör arayüzü üzerinden yazılmıştır (işaret ekle, işaret kaldır, bilgi penceresi aç, odaklan). Bu arayüzün biri Google Maps JavaScript API [6], diğeri Leaflet [8] ve OpenStreetMap için olmak üzere iki uygulaması vardır. Filtreler, haber listesi ve bilgi penceresi her iki haritada da aynı kodla çalışır.

X. DENEYSEL SONUÇLAR

A. İlk Tarama

Sistem 3 Ekim 2026 tarihinde gerçek verilerle ilk kez çalıştırılmıştır. Tarama sonunda 39 haber kaydedilmiş, 9 haber ise başka sitelerdeki kopyalarıyla birleştirilmiştir. Örneğin “Kocaeli Kitap Fuarı kapılarını açtı” haberi Ses Kocaeli, Çağdaş Kocaeli ve Özgür Kocaeli’de yayımlanmış ve tek bir kayıta, üç kaynakla gösterilmiştir. Kocaeli kontrolü ise geliştirme sırasında bu sitelerden alınan Bursa, Yalova ve İstanbul’a ait gerçek haber metinleriyle sınanmış ve bu haberleri doğru biçimde kapsam dışı bırakmıştır.

B. Sınıflandırma Hatalarının Analizi


Kaydedilen 39 haber tek tek incelendiğinde 15’inin (%38,5) yanlış sınıflandırıldığı görülmüştür. Hatalar en çok Kültürel Etkinlikler (8 haber) ve Hırsızlık (4 haber) türlerinde yoğunlaşmıştır. Hataların başlıca nedenleri ve uygulanan çözümler Tablo V’da verilmiştir. Kurallar güncellendikten sonra kayıtlı haberler, siteler yeniden taranmadan veritabanındaki metinler üzerinden yeniden sınıflandırılmıştır. Bu işlemde 15 yanlış haberin tamamı elenmiş, doğru sınıflandırılmış hiçbir haber yanlış türe geçmemiştir. Tür dağılımındaki değişim Tablo VI’de gösterilmiştir.

Ara aşamada güçlü kelime şartının bir yan etkisi de gözlenmiştir: “Devrilen motosikletin sürücüsü yaralandı” haberi 16 puan almasına rağmen güçlü kelime içermediği için elenmiştir. “Devrildi” kelimesinin ağırlığı 2’den 3’e çıkarılarak ve “ağaç devrildi” gibi ifadeler negatif kelime olarak eklenerek bu hata giderilmiştir.

Güncellenmiş kurallarla Hırsızlık türünde haber kalmamıştır. İlk sürümde bu türde görünen dört haberin hiçbirinin gerçekte bir hırsızlık olayı olmadığı (cinayet, uyuşturucu, usulsüzlük ve bir siyasi ziyaret haberi) görülmüştür; dolayısıyla boş kategori, inceleme döneminde bu türde haber yayımlanmadığını yansıtmaktadır.

C. Konum Çıkarımı

Doğru sınıflandırılmış 24 haberin konum seviyeleri Tablo VII’da verilmiştir. Haberlerin 16’sında (%66,7) olay yeri ilçe merkezinden daha spesifik bulunmuştur. İlçe seviyesinde kalan haberlerin bir kısmında metinde daha spesifik bir konum geçmemekte, bir kısmında ise metinde geçen spesifik yer servis tarafından bulunamamıştır. Örneğin “Çınarlı Kartopu Sokak” bulunamadığında sistem bir üst seviyeye düşerek “Çınarlı Mahallesi, Derince” sonucunu kullanmıştır.



Şekil 2. İlk taramadan sonra kullanıcı arayüzü (3 Ekim 2026). Solda tarih aralığı, olay türü, ilçe filtreleri ve tür başına haber sayıları; sağda türüne göre renklendirilmiş işaretlerle harita yer almaktadır. Bu ekran görüntüsü Bölüm X'te açıklanan kural düzeltmelerinden önce alınmıştır.

Tablo V
GERÇEK VERİDE GÖRÜLEN SINIFLANDIRMA HATALARI VE ÇÖZÜMLERİ

Haber	İlk tür	Neden	Çözüm
Kocaeli'de uyuşturucu operasyonu	Kültürel	“opera” kökü “operasyon” kelimesiyle eşleşti	“opera” yalnızca tam biçimleriyle eşleşir; “operasyon” negatif
Genç futbolcu Fenerbahçe'ye transfer oldu	Kültürel	“sergi” kökü “performans sergiledi” ile eşleşti	“sergi” tam biçimlerle eşleşir; “futbol”, “transfer” negatif
Kardeşini öldürdü	Hırsızlık	“şüpheli”, “tutuklandı” gibi zayıf kelimelerin toplamı	Güçlü kelime şartı; “öldür”, “cinayet” negatif
Sanayi odası meclis seçimi	Elektrik	Firma adlarındaki “elektrik”, “trafo”	“sanayi odası”, “seçim” negatif
Darica'ya yeni kavşak yapılacak	Trafik	“kazaların önüne geçmek” ifadesi	“yeni kavşak”, “ihale” negatif
Milletvekili mağdurları dinledi	Hırsızlık	“çalındı” kelimesinin mecaz anlamı	Ağırlık 4 → 3 (tek başına eşiği aşamaz)

Tablo VI
TÜR DAĞILIMI: İLK SÜRÜM VE GÜNCELLENMİŞ KURALLAR

Tür	İlk sürüm	Güncel
Trafik Kazası	10	8
Yangın	4	4
Elektrik Kesintisi	2	1
Hırsızlık	4	0
Kültürel Etkinlikler	19	11
Toplam	39	24

Tablo VII
24 HABERDE BULUNAN KONUM SEVİYELERİ

Seviye	Haber	Oran
Cadde/sokak	6	%25,0
Belirli yer	7	%29,2
Mahalle	3	%12,5
İlçe	8	%33,3

D. Tekrarlı Haber Tespitinin Sınırı

6 Ekim 2026 tarihli taramada, aynı kazayı farklı sözcüklerle aktaran iki haberin (“Büyükşehir’i kahreden kaza...” ve “UlaşımPark şoförü kazada ağır yaralandı...”) birleştirilmediği

görülmüştür. Bu haberlerin benzerliği %90 eşliğinin altında kalmıştır. Eşğin düşürülmesi bu tür eşleşmeleri yakalayabilir, ancak farklı olayların yanlışlıkla birleştirilme riskini artırır. Eşik, proje dokümanında belirtilen değerde bırakılmıştır.

E. Otomatik Testler

Sistem için 62 otomatik test yazılmıştır. Testler temizleme, sınıflandırma, konum çıkarımı, sayfa ayrıştırma, geocoding, işlem hattı ve API uçlarını kapsamaktadır. Gerçek taramada bulunan her hata ayrıca bir test örneğine dönüştürülmüştür; böylece ileride yapılacak değişikliklerin aynı hatayı yeniden ortaya çıkarması engellenmiştir. Testler gerçek veritabanı ve dış servis gerektirmeden, sahte (mock) bileşenlerle çalışır.

XI. KARŞILAŞILAN SORUNLAR VE ÇÖZÜMLER

Ulusal haberler: Yerel siteler başka illerin haberlerini de yayımlamaktadır. Bu sorun, yön ifadelerini dışlayan puanlamalı Kocaeli kontrolü ve geocoding sonucundaki il doğrulamasıyla çözülmüştür.

Türkçenin eklemeli yapısı: Kök eşleşme, ekleri yakalamak için gereklidir; ancak “opera/operasyon”, “sergi/sergiledi”, “konser/konserve” gibi tuzaklar oluşturmuştur. Bu kelimeler yalnızca belirli biçimleriyle eşleşecek şekilde tanımlanmıştır. Ünsüz yumuşaması da (“verilemeyecek” → “verilemeyeceği”)

kelimelerin kaçırılmasına yol açtığı için ilgili kelimeler yumuşayan harften önce kesilmiştir (“elektrik verilemeye”).

Çok anlamlılık: “Çalındı” kelimesi hırsızlık dışında “kapı çalındı”, “İstiklal Marşı çalındı” veya mecazi olarak “emeğimiz çalındı” anlamlarında da kullanılmaktadır. Bu, anahtar kelime tabanlı yöntemin temel sınırlarından birini göstermektedir.

Bot koruması: Bazı siteler otomatik istekleri engellemiştir. Gerçek bir tarayıcıya benzer istek başlıkları, istekler arası bekleme ve tarayıcı TLS parmak izini taklit eden yedek bir istemci kullanılmıştır.

Ödeme yöntemi: Google Cloud faturalandırması yalnızca uluslararası geçerli ve ön ödemeli olmayan kartları kabul etmektedir. Geliştirme sürecinde bu koşulu sağlayan bir kart bulunamadığı için servis seçimi soyutlanmış ve testler OpenStreetMap servisleriyle yapılmıştır. Google API anahtarları tanımlandığında sistem herhangi bir kod değişikliği olmadan Google servislerine geçmektedir.

XII. SONUÇ VE GELECEK ÇALIŞMALAR

Bu çalışmada beş yerel haber sitesinden haber toplayan, sınıflandıran, konumlandıran, tekrarları birleştiren ve harita üzerinde sunan uçtan uca bir sistem geliştirilmiştir. Gerçek verilerle yapılan deneyler, kural tabanlı yöntemlerin doğru tasarlandığında yüksek açıklanabilirlik sağladığını, ancak dilin eklemeli ve çok anlamlı yapısına karşı dikkatli bir hata analizi gerektirdiğini göstermiştir. Her kararın (eşleşen kelimeler, puanlar, denenen adresler) veritabanında saklanması, bu hata analizini mümkün kılmıştır.

Gelecek çalışmalarda anahtar kelime yönteminin, etiketli haberlerle ince ayar yapılmış Türkçe bir dil modeliyle desteklenmesi planlanabilir. Konum çıkarımı Türkçe adlandırılmış varlık tanıma (NER) modelleriyle güçlendirilebilir. Ayrıca “Kocaeli’nin 6 ilçesi elektriksiz kalacak” gibi birden fazla yeri ilgilendiren haberler için birden fazla işaret gösterilmesi ve benzerlik eşliğinin etiketli bir veri kümesi üzerinde kalibre edilmesi sistemi iyileştirecektir.

KAYNAKLAR

- [1] N. Reimers and I. Gurevych, “Sentence-BERT: Sentence embeddings using Siamese BERT-networks,” in *Proc. Conf. Empirical Methods in Natural Language Processing (EMNLP-IJCNLP)*, Hong Kong, 2019, pp. 3982–3992.
- [2] N. Reimers and I. Gurevych, “Making monolingual sentence embeddings multilingual using knowledge distillation,” in *Proc. Conf. Empirical Methods in Natural Language Processing (EMNLP)*, 2020, pp. 4512–4525.
- [3] Hugging Face, “sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2,” model kartı. [Çevrimiçi]. Erişim: <https://huggingface.co/sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2>
- [4] MongoDB, Inc., “MongoDB documentation.” [Çevrimiçi]. Erişim: <https://www.mongodb.com/docs/>
- [5] Google, “Geocoding API overview.” [Çevrimiçi]. Erişim: <https://developers.google.com/maps/documentation/geocoding/overview>
- [6] Google, “Maps JavaScript API.” [Çevrimiçi]. Erişim: <https://developers.google.com/maps/documentation/javascript>
- [7] OpenStreetMap Foundation, “Nominatim usage policy.” [Çevrimiçi]. Erişim: <https://operations.osmfoundation.org/policies/nominatim/>
- [8] V. Agafonkin, “Leaflet: An open-source JavaScript library for interactive maps.” [Çevrimiçi]. Erişim: <https://leafletjs.com/>
- [9] L. Richardson, “Beautiful Soup documentation.” [Çevrimiçi]. Erişim: <https://www.crummy.com/software/BeautifulSoup/bs4/doc/>

- [10] Pallets, “Flask documentation.” [Çevrimiçi]. Erişim: <https://flask.palletsprojects.com/>
- [11] A. Grönholm, “Advanced Python Scheduler (APScheduler).” [Çevrimiçi]. Erişim: <https://apscheduler.readthedocs.io/>
- [12] Schema.org, “NewsArticle.” [Çevrimiçi]. Erişim: <https://schema.org/NewsArticle>